

PROPOSTA DETALHADA DE ANÁLISE DE DADOS

Predição Preventiva do Abandono Escolar em Roraima

Base longitudinal escola-ano 2019-2025 | Indicadores INEP | Versão metodológica 1.0

Finalidade: pesquisa aplicada e apoio à priorização preventiva de escolas para ações de permanência escolar

Boa Vista - RR | 17 de setembro de 2026

1. Síntese executiva

Esta proposta define uma metodologia completa para transformar a base longitudinal de indicadores educacionais de Roraima em um sistema de análise e predição de risco de abandono escolar no nível da escola. O foco não é automatizar decisões sobre estudantes nem produzir um ranking punitivo de escolas. O objetivo é criar evidência quantitativa para orientar prevenção: identificar, com antecedência, escolas e etapas de ensino em que o abandono no ano seguinte tende a ser maior, explicitar quais fatores contribuem para esse risco e apoiar a seleção de intervenções de acompanhamento.

A base consolidada contém 6.054 observações escola-ano, 59 variáveis e 934 escolas distintas entre 2019 e 2025. A chave longitudinal é o código INEP da escola (CO_ENTIDADE). Os grupos de variáveis atualmente integrados são média de alunos por turma (ATU), distorção idade-série (TDI), esforço docente (IED), aprovação, reprovação e abandono. Foram acrescentadas variáveis de defasagem, tendência anual e desfecho no ano seguinte (t+1).

A estratégia recomendada é construir dois modelos principais, um para os anos finais do Ensino Fundamental e outro para o Ensino Médio. Em cada etapa, a análise deve combinar: descrição longitudinal; modelos de referência simples; modelos estatísticos interpretáveis; algoritmos de machine learning; validação estritamente temporal; análise de calibração; explicabilidade; testes de robustez para o período da pandemia; e avaliação de estabilidade por município, localização urbana/rural e dependência administrativa.

O desenho temporal proposto evita a principal fonte de erro em estudos preditivos com dados longitudinais: misturar o futuro no treinamento do passado. O conjunto de validação principal será a transição 2023 -> 2024 e o teste final será 2024 -> 2025. O desempenho final apresentado no artigo deve vir do teste 2024 -> 2025, mantido fora das decisões de seleção de modelo e hiperparâmetros.

1.1. Produto analítico pretendido

- Probabilidade de ocorrência de abandono no ano seguinte por escola e etapa.
- Estimativa da taxa esperada de abandono no ano seguinte.
- Faixa de risco ou prioridade, acompanhada de incerteza e justificativas interpretáveis.
- Lista de fatores associados ao risco em nível global e por escola.
- Painel de monitoramento para gestores, com foco em prevenção e não em responsabilização automática.
- Protocolo científico reproduzível para publicação de artigo sobre predição de abandono escolar em Roraima.

1.2. Princípio central de uso

O modelo deve ser tratado como um instrumento de triagem. Uma escola com risco predito elevado entra em uma fila de análise e acompanhamento humano. O resultado não demonstra que a escola, a direção ou os professores causaram o abandono, nem substitui diagnóstico local. Predição e causalidade são objetivos distintos.

2. Pergunta de pesquisa, objetivo e hipóteses

2.1. Pergunta principal

Com indicadores escolares consolidados no ano t, é possível prever, com utilidade operacional e estabilidade temporal, a taxa ou a ocorrência de abandono no ano t+1 em escolas públicas de Roraima, especialmente nos anos finais do Ensino Fundamental e no Ensino Médio?

2.2. Objetivo geral

Desenvolver e validar uma metodologia de predição longitudinal do abandono escolar em Roraima capaz de apoiar ações preventivas junto às escolas, priorizando interpretabilidade, validação fora do tempo, robustez e aplicabilidade para gestão pública.

2.3. Objetivos específicos

- Caracterizar a evolução do abandono escolar por etapa, município, localização e dependência administrativa entre 2019 e 2025.
- Quantificar a persistência temporal do abandono e sua associação com distorção idade-série, tamanho médio de turma, esforço docente e reprovação.
- Comparar modelos estatísticos e de machine learning contra referências simples.
- Avaliar a capacidade de prever taxa futura e de priorizar escolas com maior risco.
- Avaliar calibração, incerteza, estabilidade temporal e desempenho em subgrupos.
- Produzir explicações globais e locais que possam ser discutidas com gestores.
- Definir um procedimento de uso que transforme risco predito em ação preventiva, sem automatizar decisões de alto impacto.

2.4. Hipóteses analíticas

- H1: há persistência relevante entre o abandono histórico da escola e o abandono do ano seguinte.
- H2: maior distorção idade-série está associada a maior risco futuro de abandono, especialmente nos anos finais e no Ensino Médio.
- H3: reprovação e deterioração recente dos indicadores agregam informação preditiva além do histórico de abandono.
- H4: modelos não lineares podem melhorar a capacidade de priorização, mas o ganho deve ser comparado a modelos simples para justificar maior complexidade.
- H5: o período 2020-2021 representa uma quebra estrutural e pode reduzir a transportabilidade de relações aprendidas se for tratado como período comum.
- H6: o IED pode adicionar informação, mas sua inclusão reduz a janela histórica desta versão; por isso, deve ser avaliado como enriquecimento incremental.

3. Base de dados e arquitetura longitudinal

3.1. Unidade de análise

A unidade de observação é escola-ano. Cada linha representa uma escola em determinado ano, identificada por CO_ENTIDADE. Essa escolha torna o desenho apropriado para priorização de unidades escolares, e não para predição individual de estudantes.

3.2. Dimensão e cobertura

Ano	Escolas	Públicas	ATU	TDI	IED	Rendimento	Alvo AF t+1	Alvo EM t+1
2019	843	798	667	666	0	666	237	157
2020	841	800	662	661	0	660	233	158
2021	835	796	651	650	651	650	235	160
2022	864	823	682	681	682	679	232	166
2023	880	836	690	689	690	689	239	168
2024	897	853	697	695	697	695	243	171
2025	894	854	687	687	689	687	0	0

A união das fontes foi usada como universo da base. Isso preserva escolas que não possuem um indicador específico em determinado ano. A ausência é mantida como nula, nunca convertida automaticamente para zero.

3.3. Grupos de variáveis

Grupo	Exemplos	Papel esperado
-------	----------	----------------

Identificação	ANO, CO_ENTIDADE, município, localização, dependência	Chave longitudinal e estratificação
ATU	ATU_FUN_AF, ATU_MED_TOTAL	Contexto de tamanho médio de turma
TDI	TDI_FUN_AF, TDI_MED_TOTAL	Trajetória escolar acumulada
IED	IED_FUN_N1..N6, IED_MED_N1..N6, IED * ALTO	Esforço docente agregado
Rendimento	aprovação, reprovação, abandono	Desfecho corrente e contexto acadêmico
Histórico	ABANDONO * LAG1	Persistência temporal
Tendência	TDI * DELTA1, ATU * DELTA1, ABANDONO * DELTA1	Mudança recente
Desfecho futuro	ABANDONO * T1	Alvo para treinamento e avaliação
Disponibilidade	DISP_ATU, DISP_TDI, DISP_IED, DISP_REND	Controle de ausência estrutural

3.4. Fontes e rastreabilidade

As fontes centrais são indicadores educacionais do INEP. O Censo Escolar coleta informações sobre escolas, turmas, alunos e profissionais e, na etapa de Situação do Aluno, registra rendimento e movimento ao final do ano letivo. As taxas de rendimento derivadas dessa etapa incluem aprovação, reprovação e abandono. O INEP também publica, por escola, indicadores como média de alunos por turma, distorção idade-série e esforço docente. A base derivada preserva os arquivos brutos fora da pasta de processados e registra um manifesto de fontes por ano.

Nesta coleção, os arquivos escolares de IED utilizados estão disponíveis para 2021-2025. Os valores de IED de 2019-2020 permanecem ausentes nesta versão. Isso deve ser tratado como ausência estrutural da coleção processada, e não como valor zero.

4. Definição do desfecho e do momento de previsão

4.1. Desfechos principais

Serão avaliados separadamente dois desfechos contínuos: ABANDONO_FUN_AF_T1 e ABANDONO_MED_T1, que representam a taxa de abandono observada no ano seguinte para anos finais do Ensino Fundamental e Ensino Médio. Em paralelo, serão construídos desfechos binários auxiliares para tarefas de triagem.

4.2. Duas tarefas complementares

Tarefa	Definição	Uso
Regressão	Predizer a taxa percentual de abandono em t+1	Estimar intensidade esperada do problema
Classificação/triagem	Predizer ocorrência ou risco alto em t+1	Priorizar escolas para acompanhamento

A regressão será o objetivo quantitativo principal. A classificação será tratada como ferramenta operacional e não deve usar um limiar arbitrário sem análise. Serão testadas pelo menos duas definições: (a) qualquer abandono > 0; e (b) risco alto definido por quantil dentro da etapa/ano ou por limite operacional acordado com a gestão. O artigo deve reportar como o limiar foi escolhido e fazer análise de sensibilidade.

4.3. Momento operacional

O cenário implementável com esta base é uma previsão anual de planejamento: indicadores consolidados do ano t são usados para orientar ações no ano t+1. Isso significa que o sistema pode apoiar planejamento de visitas, monitoramento e alocação de apoio antes do encerramento do ano-alvo. Para uma previsão durante o próprio ano letivo seria necessária uma segunda arquitetura com dados de maior frequência - presença mensal, notas bimestrais, transferência/movimento e alertas administrativos.

4.4. Regra de prevenção de vazamento

Nenhuma variável calculada a partir de t+1 pode entrar como preditor. Colunas com sufixo _T1 são desfechos. Além disso, variáveis de rendimento do próprio ano t só podem ser usadas se, no cenário operacional declarado, já estariam disponíveis no momento da previsão. Por isso serão definidos dois cenários:

- Cenário A - planejamento pós-fechamento do ano: pode usar rendimento consolidado de t para prever t+1.
- Cenário B - alerta antecipado antes do fechamento: exclui abandono e demais taxas finais de rendimento de t, usando apenas indicadores disponíveis antes do encerramento. Esse cenário será uma análise de robustez e aproximação; uma versão verdadeiramente intra-anual exigirá novas fontes.

5. Qualidade, consistência e preparação dos dados

5.1. Validações já executadas

- 6.054 chaves ANO + CO_ENTIDADE e 6.054 chaves únicas: zero duplicidade.
- Nenhuma taxa observada fora do intervalo de 0 a 100.
- Nenhum valor ATU não positivo entre os valores observados.
- Em 4.574 observações completas do Ensino Fundamental, aprovação + reprovação + abandono = 100, sem violações da tolerância de 0,2 ponto percentual.
- Nos anos finais, 1.749 combinações completas fecham em 100; no Ensino Médio, 1.215.
- Para IED, 3.299 combinações completas do Ensino Fundamental e 883 do Ensino Médio têm soma dos níveis 1-6 igual a 100 dentro da tolerância.
- Nenhuma escola muda de município ou dependência administrativa no mesmo código INEP na série; seis apresentam mudança urbana/rural e 105 apresentam variação de nome, compatível com renomeações/ajustes cadastrais.

5.2. Ausência de dados

A ausência deve ser estudada como fenômeno próprio. Para cada variável serão produzidos: percentual ausente por ano, por município, por localização e por dependência; mapa de padrões de ausência; e teste de associação entre ausência e desfecho. Não se adotará imputação única antes de compreender a estrutura de faltantes.

Serão comparadas três estratégias: modelos que tratam nulos nativamente; imputação por mediana estratificada por ano/etapa acompanhada de indicador de ausência; e análise completa apenas como referência de sensibilidade. A imputação será ajustada dentro de cada conjunto de treinamento, nunca usando informação do período de teste.

5.3. Outliers e consistência longitudinal

Valores extremos não serão removidos automaticamente. Primeiro será verificado se são plausíveis e recorrentes. Serão produzidos gráficos de trajetória por escola, boxplots por ano e tabelas dos maiores saltos anuais. Eventuais winsorizações, se utilizadas, serão restritas ao treinamento e comparadas a modelos sem transformação.

6. Análise exploratória longitudinal

6.1. Evolução do abandono

Ano	AF - média	AF - mediana	AF - % zero	EM - média	EM - mediana	EM - % zero
2019	5,42	3,70	22,2%	10,71	7,15	17,7%
2020	1,04	0,00	71,7%	1,67	0,00	70,7%
2021	3,13	1,30	41,9%	5,83	2,30	35,8%

2022	5,22	3,50	24,3%	12,05	10,55	11,1%
2023	3,16	1,50	31,8%	7,58	6,00	14,4%
2024	2,75	1,40	35,0%	5,74	3,65	25,0%
2025	2,53	0,80	43,0%	6,20	4,50	19,1%

Os números mostram que a distribuição é assimétrica e contém muitos zeros. O comportamento de 2020 é marcadamente diferente: a proporção de escolas com taxa zero ultrapassa 70% em ambas as etapas. Isso sustenta o uso de modelos de duas partes e exige análise de sensibilidade para a pandemia.

6.2. Análises exploratórias previstas

- Séries anuais de média, mediana, percentis 75 e 90 e proporção de zero por etapa.
- Distribuições por município, urbano/rural e rede estadual/municipal/federal.
- Matrizes de correlação de Spearman por ano e por etapa, com intervalos por bootstrap.
- Autocorrelação do abandono por escola: t com t+1 e t-1 com t+1.
- Curvas de risco não lineares entre TDI, reprovação, ATU, IED e abandono futuro.
- Análise de estabilidade das associações antes, durante e após 2020-2021.
- Clusterização apenas exploratória de trajetórias, sem usar o cluster como verdade causal.

7. Tratamento da ruptura 2020-2021

A pandemia e mudanças excepcionais de calendário, frequência, avaliação e fluxo podem produzir uma quebra de regime. Um modelo treinado sem reconhecer essa ruptura pode aprender relações que não representam o período atual.

7.1. Estratégia de sensibilidade

Análise	Amostra	Objetivo
S1 - Série completa	Transições 2019->2020 a 2024->2025	Medir desempenho com toda a informação histórica
S2 - Pós-período crítico	Preditores 2021-2024, alvos 2022-2025	Aproximar o regime educacional mais recente
S3 - Sem alvos 2020-2021	Excluir transições cujo desfecho cai em 2020 ou 2021	Testar impacto direto do período excepcional
S4 - Indicador de período	Manter tudo com dummies/efeitos de ano	Permitir ajuste explícito à mudança de nível

A conclusão científica deve enfatizar relações que permaneçam razoavelmente estáveis entre essas especificações. Se o desempenho depender fortemente de 2020-2021, isso deve ser reportado como limitação de transportabilidade.

8. Estratégia de modelagem

8.1. Modelos de referência obrigatórios

Antes de algoritmos complexos, serão definidos baselines que qualquer modelo deve superar. Sem isso, um resultado aparentemente alto pode apenas refletir persistência temporal.

Código	Baseline	Descrição
B0	Média histórica por etapa/ano	Prevê o valor médio do treinamento
B1	Persistência	Prevê abandono(t+1) = abandono(t)
B2	Mediana estratificada	Mediana por etapa, localização e dependência
B3	Regressão linear regularizada	Ridge/Elastic Net com variáveis padronizadas
B4	Logística regularizada	Para desfechos binários de triagem

8.2. Modelos estatísticos interpretáveis

- Regressão linear/Elastic Net para taxa futura, com erros robustos e avaliação de resíduos.
- Modelos de duas partes: primeiro classificar se abandono > 0; depois estimar magnitude condicional.
- Modelo misto com intercepto aleatório por escola, quando a especificação e o tamanho de amostra permitirem, para separar heterogeneidade persistente da escola e variação anual.
- Modelos aditivos generalizados para capturar relações não lineares suaves com TDI, reprovação e ATU.
- Regressão beta ou quasi-binomial apenas como análise complementar, com tratamento explícito de zeros/uns.

8.3. Modelos de machine learning

- Random Forest como referência não linear baseada em árvores.
- Gradient Boosting (XGBoost, LightGBM ou implementação equivalente), com regularização forte e busca de hiperparâmetros restrita.
- CatBoost como alternativa robusta para mistura de variáveis numéricas/categóricas e valores ausentes.
- Explainable Boosting Machine (EBM), se disponível, como opção de alta interpretabilidade com efeitos não lineares.
- Ensemble somente se produzir ganho consistente no teste temporal e manter explicabilidade suficiente.

Redes neurais profundas não serão prioridade nesta fase. O tamanho efetivo de amostra para os desfechos é pequeno em comparação com problemas típicos de deep learning: aproximadamente 1.419 linhas públicas com alvo futuro nos anos finais e 980 no Ensino Médio entre 2019 e 2024. Modelos tabulares regulares e interpretáveis são mais adequados ao desenho inicial.

8.4. Duas famílias de conjuntos de atributos

Versão	Janela	IED	Finalidade
Core	2019-2024	Não obrigatório	Maximizar histórico e comparabilidade temporal
Core+IED	2021-2024	Incluído	Medir valor incremental do esforço docente
Early-warning aproximado	conforme disponibilidade	Opcional	Excluir rendimento final de t para reduzir dependência de informações disponíveis apenas após fechamento
Enriquecido Censo	fase 2	Incluído quando aplicável	Adicionar estrutura, matrícula, docentes e turmas harmonizadas

9. Desenho de validação temporal

9.1. Partição principal

Conjunto	Preditor t	Desfecho t+1	Uso
Treinamento	2019-2022	2020-2023	Ajuste do modelo e estimativa de parâmetros
Validação temporal	2023	2024	Seleção de versão e hiperparâmetros
Teste final	2024	2025	Avaliação final não tocada durante desenvolvimento

O teste 2024->2025 deve ser bloqueado até que a especificação final esteja congelada. Nenhum limiar, escolha de variável ou hiperparâmetro pode ser otimizado olhando seu resultado.

9.2. Validação walk-forward adicional

Além da divisão principal, será usada validação de origem temporal crescente. Exemplo: treinar até 2020 e avaliar 2021; treinar até 2021 e avaliar 2022; e assim sucessivamente. O objetivo não é apenas obter uma média de desempenho, mas observar estabilidade: um modelo útil para gestão deve manter desempenho aceitável em diferentes transições anuais.

9.3. Evitar vazamento por escola

Em um problema longitudinal é normal a mesma escola aparecer em treino e teste de anos futuros, pois esse é o cenário de produção: queremos prever a próxima observação de escolas conhecidas. Entretanto, será conduzida uma análise adicional de generalização para escolas pouco observadas ou novas, por exemplo deixando grupos de escolas fora do treinamento. Essa análise mede transportabilidade, mas não substitui o teste temporal principal.

10. Métricas de avaliação

10.1. Para regressão da taxa

- MAE - erro absoluto médio: medida principal de erro em pontos percentuais.
- RMSE - penaliza erros grandes e ajuda a identificar falhas em escolas de alto abandono.
- MedAE - erro absoluto mediano, robusto a extremos.
- R2 apenas como medida complementar, nunca isoladamente.
- Correlação de Spearman entre predição e observado para medir qualidade de ordenação.
- Erro nos percentis superiores e Top-K para avaliar justamente as escolas que seriam priorizadas.

10.2. Para classificação de risco

- PR-AUC como métrica central quando a classe positiva for rara ou operacionalmente prioritária.
- ROC-AUC como medida complementar.
- Recall/sensibilidade das escolas de maior risco.
- Precisão/valor preditivo positivo nas escolas selecionadas para intervenção.
- F1 ou F-beta com beta > 1 quando perder uma escola de alto risco for mais custoso que gerar um alerta adicional.
- Brier Score e curvas de calibração para avaliar se probabilidades previstas correspondem às frequências observadas.

10.3. Métricas de priorização operacional

Como a gestão tende a possuir capacidade limitada de intervenção, será simulada uma política Top-K. Exemplo: se for possível acompanhar 30 escolas, medir quantas das 30 com maior abandono observado no ano seguinte estavam entre as 30 maiores predições. Serão avaliados Recall@K, Precision@K, ganho acumulado e lift em diferentes capacidades K.

11. Engenharia de atributos

11.1. Variáveis já disponíveis

- Níveis correntes de ATU, TDI, IED, aprovação, reprovação e abandono.
- Defasagens de abandono em t-1.
- Variações anuais (delta) de TDI, ATU e abandono.
- Localização urbana/rural, município e dependência administrativa.
- Indicadores de disponibilidade por fonte.

11.2. Atributos derivados a testar

- Médias móveis de dois ou três anos, quando houver histórico suficiente.
- Inclinação temporal por escola para TDI, reprovação e abandono.
- Número de anos consecutivos com abandono acima de zero ou acima de determinado percentil.
- Diferença da escola para a mediana do município e da dependência no mesmo ano.
- Percentil da escola dentro do município/ano, reduzindo sensibilidade a mudanças globais de escala.
- Interações pré-especificadas: TDI x reprovação; rural x TDI; esforço docente alto x tamanho de turma.
- Indicadores de quebra/mudança abrupta quando o delta exceder limiar robusto baseado em IQR.

Toda engenharia que usa estatísticas de grupos deve ser calculada sem consultar o desfecho do teste e, quando necessário, ajustada somente no treinamento.

12. Desbalanceamento, zeros e distribuição do desfecho

A taxa de abandono apresenta massa relevante em zero e cauda à direita. Por isso, o plano principal evita depender de uma única métrica ou de regressão linear simples. O modelo de duas partes é especialmente adequado: primeiro estimar a probabilidade de abandono positivo e, depois, a magnitude quando positivo.

Para classificação, reamostragem como SMOTE não será usada automaticamente. Em séries temporais pequenas, sintetizar observações pode distorcer estrutura anual. A prioridade será ponderação de classe, ajuste de limiar, métricas de ranking e calibração. Qualquer técnica de reamostragem será limitada ao treinamento e comparada a alternativas sem dados sintéticos.

13. Interpretabilidade e explicações

13.1. Explicação global

- Coeficientes padronizados para modelos lineares/regularizados.
- Importância por permutação em conjunto de validação/teste.
- SHAP ou método equivalente para modelos de árvore, com cautela em variáveis correlacionadas.
- Curvas de dependência parcial/ALE para relações não lineares.
- Análise de estabilidade da importância por ano.

13.2. Explicação por escola

Para cada escola priorizada, o sistema deve produzir um resumo do tipo: risco previsto, histórico recente, fatores que aumentaram o risco e fatores protetivos relativos ao padrão do modelo. O texto deve deixar claro que os fatores são associações preditivas, não causas comprovadas.

13.3. Contrafactuais e recomendações

Não se recomenda gerar recomendações automáticas do tipo "reduza TDI em X pontos para eliminar o abandono". Alterar uma variável observacional em um modelo preditivo não equivale a uma intervenção causal. A etapa de recomendação deve relacionar fatores preditivos a um catálogo separado de intervenções com evidência, validado por especialistas em educação.

14. Equidade, governança e uso responsável

14.1. Avaliação por subgrupos

O desempenho será reportado, quando houver amostra suficiente, por localização urbana/rural, dependência estadual/municipal/federal e grupos de municípios. Serão comparados erro, recall, precisão e calibração. Diferenças substanciais devem ser investigadas antes do uso operacional.

14.2. Contextos indígenas, fronteiriços e rurais

Roraima possui contextos educacionais muito heterogêneos. Escolas indígenas, rurais, fronteiriças e de áreas remotas podem apresentar processos de registro, estrutura de oferta e restrições logísticas diferentes. O modelo não deve converter essas características em julgamento de qualidade. Sempre que possível, esses contextos devem ser avaliados separadamente e interpretados com conhecimento local.

14.3. Governança

- Manter versão, data e hash das bases e modelos.
- Registrar quais anos e variáveis alimentaram cada experimento.
- Não expor resultados de risco fora do público autorizado quando puderem gerar estigmatização.
- Exigir revisão humana antes de qualquer decisão de intervenção ou comunicação pública.
- Reavaliar o modelo quando houver mudança relevante de política, coleta ou calendário escolar.
- Documentar limitações e desempenho por período no relatório final.

15. Matriz de experimentos proposta

Exp.	Etapas	Atributos	Modelo	Pergunta
E0	AF/EM	Histórico mínimo	Persistência	É possível superar abandono(t) como previsão de t+1?
E1	AF/EM	Core	Elastic Net	Quanto explica um modelo linear regularizado?
E2	AF/EM	Core	GAM/EBM	Há ganho com não linearidade interpretável?
E3	AF/EM	Core	Random Forest	Árvores capturam interações úteis?
E4	AF/EM	Core	Gradient Boosting/CatBoost	Há ganho robusto no teste temporal?
E5	AF/EM	Core+IED	Melhor E1-E4	IED melhora desempenho pós-2021?
E6	AF/EM	Sem rendimento final de t	Melhor modelo	Qual desempenho com alerta mais antecipado?
E7	AF/EM	Core	Melhor modelo	Resultados resistem à exclusão de 2020-2021?
E8	AF/EM	Core + Censo harmonizado	Melhor modelo	Quanto a camada estrutural do Censo agrega?

15.1. Regra de seleção

O modelo final não será o que obtiver a maior métrica isolada na validação. A seleção combinará: melhora sobre baseline; estabilidade entre anos; MAE/PR-AUC; calibração; desempenho em Top-K; desempenho por subgrupos; complexidade; e interpretabilidade. Um ganho pequeno de acurácia com perda grande de transparência pode não justificar adoção.

16. Segunda etapa: enriquecimento com Censo Escolar

A pasta de dados do projeto contém microdados do Censo Escolar de 2019 a 2024 e tabelas de 2025 para escola, matrícula, turma e docente. Recomenda-se incorporá-los após o modelo-base estar estável, porque isso permite medir claramente o ganho incremental de cada nova família de atributos.

16.1. Variáveis candidatas

- Porte da escola e total de matrículas por etapa.
- Composição de matrícula por idade, modalidade e turno, conforme comparabilidade anual.
- Percentual de matrículas em tempo integral.
- EJA, educação especial e outras modalidades relevantes.
- Infraestrutura física e tecnológica da escola.

- Quantidade e perfil agregado de docentes.
- Tamanho e quantidade de turmas.
- Complexidade de gestão e outros indicadores INEP que possam ser harmonizados.
- Indicadores territoriais externos em nível municipal, desde que temporais e obtidos de fonte oficial.

16.2. Harmonização

O principal desafio dessa etapa não é o algoritmo, mas a consistência entre anos. Será criado um mapa de equivalência de nomes e conceitos de variáveis. Uma variável só entrará na série longitudinal se tiver definição suficientemente estável ou se a quebra puder ser modelada explicitamente. O dicionário deve registrar origem, ano de disponibilidade, transformação e regras de ausência.

17. Transformação do modelo em instrumento preventivo

17.1. Saída sugerida para gestores

Campo	Conteúdo
Escola	Código INEP e nome
Etapa	Anos finais ou Ensino Médio
Risco previsto	Probabilidade calibrada de risco/ocorrência
Taxa prevista	Estimativa percentual para t+1
Faixa de incerteza	Intervalo ou faixa de confiança preditiva
Prioridade	Faixa operacional definida pela capacidade de intervenção
Principais fatores	3-5 contribuições preditivas com linguagem simples
Histórico	Abandono, TDI, reprovação e tendências recentes
Ação	Campo preenchido pela equipe humana após diagnóstico local
Acompanhamento	Registro de retorno e resultado da intervenção

17.2. Ciclo de uso

1. Gerar previsões anuais com dados fechados do ano t.
2. Selecionar escolas prioritárias conforme capacidade de atendimento, não apenas um limiar estatístico fixo.
3. Realizar diagnóstico qualitativo/administrativo com a escola.
4. Definir plano de ação adequado ao contexto local.
5. Monitorar indicadores durante o ano t+1.
6. Registrar intervenções para, futuramente, avaliar efetividade e construir um componente causal.

18. Estrutura sugerida para o artigo científico

18.1. Título provisório

Predição Longitudinal do Abandono Escolar em Roraima: um Modelo de Alerta Preventivo Baseado em Indicadores Educacionais do INEP

18.2. Estrutura

Seção	Conteúdo principal
Introdução	Problema do abandono, contexto de Roraima, lacuna e contribuição.
Trabalhos relacionados	Early warning systems, dropout prediction, modelos tabulares, interpretabilidade.
Dados	Fontes INEP, base 2019-2025, unidade escola-ano, cobertura e limitações.
Método	Construção t->t+1, prevenção de vazamento, modelos, validação temporal e métricas.
Resultados	EDA, comparação com baselines, teste 2024->2025,

	calibração, Top-K e subgrupos.
Interpretabilidade	Fatores globais, curvas de efeito e exemplos de explicação por escola anonimizados quando necessário.
Robustez	Pandemia, IED, cenários de antecipação e sensibilidade.
Discussão	Aplicabilidade, limitações, não causalidade e implicações para gestão.
Conclusão	Síntese, uso preventivo e próximos passos.

18.3. Tabelas e figuras mínimas do artigo

- Tabela de cobertura da base por ano e etapa.
- Figura da evolução anual do abandono em AF e EM.
- Figura do desenho temporal de treino/validação/teste.
- Tabela de desempenho dos baselines e modelos.
- Curvas de calibração para o melhor classificador.
- Gráfico de Precision-Recall e desempenho Top-K.
- Importância/efeitos das principais variáveis.
- Tabela de robustez por cenário de pandemia e conjunto de atributos.
- Tabela de desempenho por subgrupos/contextos.

19. Reprodutibilidade, trilha de auditoria e versionamento

- Congelar a base analítica usada em cada versão do artigo.
- Guardar dicionário, manifesto de fontes e relatório de validação junto da base.
- Registrar semente aleatória e versões de bibliotecas.
- Usar pipeline de pré-processamento ajustado apenas no treino.
- Salvar hiperparâmetros e métricas por split temporal.
- Gerar hash dos arquivos de entrada e saída relevantes.
- Separar notebook de exploração de script reprodutível de produção.
- Registrar todas as decisões tomadas após observar a validação, antes de liberar o teste final.

20. Critérios de sucesso

O estudo será considerado metodologicamente bem-sucedido se demonstrar, com teste temporal fora da amostra, que ao menos um modelo supera baselines simples e mantém desempenho suficientemente estável para priorização preventiva. O valor prático não será definido apenas por R2 ou AUC, mas pela capacidade de identificar uma parcela relevante das escolas com maior abandono futuro dentro de uma capacidade realista de intervenção, com probabilidades calibradas e explicações compreensíveis.

Mesmo que modelos complexos não superem significativamente a persistência histórica, o resultado terá valor científico: mostrará a dificuldade do problema, quantificará a informação incremental dos indicadores e definirá quais novas fontes são necessárias. Um estudo negativo, quando bem validado, é preferível a um modelo aparentemente preciso obtido com vazamento temporal.

21. Próximos passos operacionais

7. Executar EDA completa e relatório de ausência por ano.
8. Construir baselines B0-B4 para AF e EM.
9. Executar partição temporal e walk-forward.
10. Rodar modelos Core E1-E4.
11. Executar Core+IED e análises de pandemia.
12. Selecionar modelo com base em desempenho, estabilidade, calibração e interpretabilidade.
13. Congelar especificação antes de avaliar 2024->2025.

14. Produzir relatório científico e painel protótipo de priorização.
15. Harmonizar microdados do Censo para a versão 2 da base e repetir o protocolo, medindo ganho incremental.
16. Planejar piloto com gestores e registrar intervenções, criando base para futura avaliação causal de efetividade.

22. Limitações e interpretação científica

- A unidade escola-ano impede inferências sobre qual estudante específico abandonará.
- A taxa de abandono é um desfecho administrativo agregado e pode refletir regras e processos de registro.
- Associações preditivas não identificam causa.
- O número de escolas com Ensino Médio é relativamente pequeno, limitando complexidade do modelo.
- O IED reduz a janela histórica na coleção disponível.
- O período pandêmico constitui potencial quebra estrutural.
- Mudanças futuras de política educacional podem causar concept drift e exigir recalibração.
- Um ranking de risco sem contexto pode estigmatizar escolas; o uso deve ser acompanhado por governança e revisão humana.

23. Referências e fontes principais

INEP. Indicadores Educacionais. Disponível em:

<https://www.gov.br/inep/pt-br/aceso-a-informacao/dados-abertos/indicadores-educacionais> . Acesso em 17 set. 2026.

INEP. Censo Escolar. Disponível em: <https://www.gov.br/inep/pt-br/areas-de-atuacao/pesquisas-estatisticas-e-indicadores/censo-escolar> . Acesso em 17 set. 2026.

INEP. Taxas de Rendimento Escolar. Disponível em:

<https://www.gov.br/inep/pt-br/aceso-a-informacao/dados-abertos/indicadores-educacionais/taxas-de-rendimento-escolar> . Acesso em 17 set. 2026.

INEP. Taxas de Distorção Idade-série. Disponível em: <https://www.gov.br/inep/pt-br/aceso-a-informacao/dados-abertos/indicadores-educacionais/taxas-de-distorcao-idade-serie> . Acesso em 17 set. 2026.

INEP. Média de Alunos por Turma. Disponível em:

<https://www.gov.br/inep/pt-br/aceso-a-informacao/dados-abertos/indicadores-educacionais/media-de-alunos-por-turma> . Acesso em 17 set. 2026.

INEP. Esforço Docente. Disponível em:

<https://www.gov.br/inep/pt-br/aceso-a-informacao/dados-abertos/indicadores-educacionais/esforco-docente> . Acesso em 17 set. 2026.

BREIMAN, L. Random Forests. Machine Learning, 45, 5-32, 2001.

FRIEDMAN, J. H. Greedy Function Approximation: A Gradient Boosting Machine. Annals of Statistics, 29(5), 1189-1232, 2001.

SAITO, T.; REHMSMEIER, M. The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. PLOS ONE, 10(3), 2015.

LUNDBERG, S. M.; LEE, S.-I. A Unified Approach to Interpreting Model Predictions. Advances in Neural Information Processing Systems, 2017.

MOLNAR, C. Interpretable Machine Learning. 2nd ed., 2022. Disponível em:

<https://christophm.github.io/interpretable-ml-book/> .

VILLARREAL-TORRES, H.; ANGELES-MORALES, J. Predicting Student Dropout based on Machine Learning and Deep Learning: A Systematic Review. EAI Endorsed Transactions on Scalable Information Systems, 2023. DOI: 10.4108/eetsis.3586.

Apêndice A. Dicionário resumido de variáveis críticas

Variável	Descrição	Uso
CO_ENTIDADE	Código INEP da escola	Chave longitudinal
ABANDONO_FUN_AF	Taxa de abandono nos anos finais em t	Preditor histórico/corrente no cenário A
ABANDONO_MED	Taxa de abandono no Ensino Médio em t	Preditor histórico/corrente no cenário A
ABANDONO_FUN_AF_T1	Abandono nos anos finais em t+1	Desfecho
ABANDONO_MED_T1	Abandono no Ensino Médio em t+1	Desfecho
TDI_FUN_AF	Distorção idade-série nos anos finais	Preditor
TDI_MED_TOTAL	Distorção idade-série no Ensino Médio	Preditor
ATU_FUN_AF	Média de alunos por turma nos anos finais	Preditor
ATU_MED_TOTAL	Média de alunos por turma no Ensino Médio	Preditor
IED_FUN_ALTO	% docentes nos níveis 4-6 de esforço - EF	Preditor incremental
IED_MED_ALTO	% docentes nos níveis 4-6 de esforço - EM	Preditor incremental
REPROVACAO_FUN_AF	Taxa de reprovação nos anos finais	Preditor
REPROVACAO_MED	Taxa de reprovação no Ensino Médio	Preditor
* LAG1	Valor de abandono em t-1	Histórico
* DELTA1	Diferença t - (t-1)	Tendência

Apêndice B. Checklist antes da publicação dos resultados

- Teste final 2024->2025 permaneceu intocado até congelar o modelo?
- Todas as transformações foram ajustadas apenas com dados de treinamento?
- As métricas incluem baselines e intervalos de incerteza?
- PR-AUC/calibração foram usadas quando a saída é probabilística?
- Foram reportados resultados por ano e não apenas uma média global?
- Foram executadas análises de sensibilidade para 2020-2021?
- O artigo diferencia predição de causalidade?
- O uso operacional proposto inclui revisão humana?
- As limitações de granularidade escola-ano estão explícitas?
- Base, dicionário, manifesto e validação foram versionados?

Documento metodológico preparado a partir da base longitudinal consolidada em 17/09/2026. A proposta deve ser atualizada quando novas fontes forem incorporadas ou quando o horizonte operacional de previsão for alterado.